2주차 실습 과제

2017313107 이승태

- 1. 4장_Titanic dataset 탐색 및 전처리
- (1) import 하기

```
[1] import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import sklearn
from sklearn.metrics import *
from pandas import DataFrame, Series

plt.style.use('seaborn')
sns.set(font_scale=2.5)
```

(2) 데이터를 불러오고 df_train, df_test에 저장한 후, 데이터의 shape과 feature들을 출력

```
[2] #캐글사이트(https://www.kaggle.com/c/titanic/data)에서 데이터 파일을 다운로드 받은 경로에 맞게 설정하여 데이터 로드. df_train = pd.read_csv('test.csv')

[3] #학습데이터, 테스트데이터의 차원 조회 (테스트데이터에는 'survived' 칼럼이 없음) df_train.shape, df_test.shape

((891, 12), (418, 11))


[4] columns=df_train.columns columns
Index(['PassengerId', 'Survived', 'Pclass', 'Name', 'Sex', 'Age', 'SibSp', 'Parch', 'Ticket', 'Fare', 'Cabin', 'Embarked'], dtype='object')
```

(3) 0~4번의 index를 갖는 데이터 보기






(4) 각 feature들의 data type보기




(5) servived의 개수 보기

```
[8] df_train['Survived'].value_counts() #target value로 사용할 컬럼인 'Survived'의 클래스 별 데이터 수
0 549
1 342
Name: Survived, dtype: int64
```


(6) survived feature에 대한 데이터 비율 가시화 하기



(7) 결측지가 얼마나 있는지 확인



(8) 칼럼들을 제거하고 결측지를 평균값으로 대체하고 위와 마찬가지로 결측지의 개수를 확인



(9) male과 female처럼 숫자로 나타내지지 않는 것들을 숫자로 바꾸고, 너무 벗어나는 값들은 모두 제거한다.

```
[15] #문자열로 이루어진 'sex' 컬럼은 숫자로 매핑
sex_mapping = {"male": 0, "female": 1}
train['Sex'] = train['Sex'].map(sex_mapping)

#'Age', 'Fare' 컬럼에 대하여 평균으로부터 3시그마 안에 포함되지 않는 값들은 이상치로 판단하여 모두 제거
age_mean = train['Age'].mean()
age_std = train['Age'].std()
indexNames = train[train['Age'] < age_mean - 3*age_std].index
train.drop(indexNames, inplace=True)
indexNames = train[train['Age'] > age_mean + 3*age_std].index
train.drop(indexNames, inplace=True)
fare_mean = train['Fare'].mean()
fare_std = train['Fare'].std()
indexNames = train[train['Fare'] < fare_mean - 3*fare_std].index
train.drop(indexNames, inplace=True)
indexNames = train[train['Fare'] > fare_mean + 3*fare_std].index
train.drop(indexNames, inplace=True)
indexNames = train[train['Fare'] > fare_mean + 3*fare_std].index
train.drop(indexNames, inplace=True)
indexNames = train[train['Fare'] > fare_mean + 3*fare_std].index
train.drop(indexNames, inplace=True)
```

2. 4장_로지스틱회귀모형 학습 및 성능 평가

(1) train, test.csv전처리

```
[2] import numpy as np import pandas as pd import matplotlib.pyplot as plt import seaborn as sns import sklearn from sklearn from sklearn.metrics import * from pandas import DataFrame, Series

plt.style.use('seaborn') sns.set(font_scale=2.5) df_train = pd.read_csv('test.csv') df_test = pd.read_csv('test.csv') train = df_train.drop(['Cabin', 'Embarked', 'Name', 'Ticket', 'Passengerid'],axis=1) test = df_test.drop(['Cabin', 'Embarked', 'Name', 'Ticket'],axis=1) train["Age"].fillna(train.groupby("Sex")["Age"].transform("mean"), inplace=True) test["Age"].fillna(test.groupby("Sex")["Age"].transform("mean"), inplace=True) test["Fare"].fillna(test.groupby("Sex")["Fare"].transform("mean"), inplace=True) sex_mapping = {"male": 0, "female": 1} train['Sex'] = train['Sex'].map(sex_mapping) test['Sex'] = test['Sex'].map(sex_mapping) age_mean = train['Age'].mean() age_std = train['Age'].mean() age_std = train['Age'].std() indexNames = train[train('Age'] > age_mean + 3*age_std].index train.drop(indexNames, inplace=True) fare_mean = train['Fare'].std() indexNames = train[train('Fare'].std() indexNames = train[train('Fare'].std() indexNames = train[train('Fare')] > fare_mean + 3*fare_std].index train.drop(indexNames, inplace=True) indexNames = train[train('Fare')] > fare_mean + 3*fare_std].index train.drop(indexNames, inplace=True) indexNames = train[train('Fare')] > fare_mean + 3*fare_std].index train.drop(indexNames, inplace=True) indexNames = train[train('Fare')] > fare_mean + 3*fare_std].index train.drop(indexNames, inplace=True) indexNames = train[train('Fare')] > fare_mean + 3*fare_std].index train.drop(indexNames, inplace=True) indexNames = train[train('Fare')] > fare_mean + 3*fare_std].index train.drop(indexNames, inplace=True) indexNames = train[train('Fare')] > fare_mean + 3*fare_std].index train.drop(indexNames, inplace=True) indexNames = train[train('Fare')] > fare_mean + 3*fare_std].index train.drop(indexNames, inplace=True)
```

(2) survived했는지 안했는지를 label로 보기 위해 그 열을 빼낸후 label로 쓴다.

```
[3] from sklearn.linear_model import LogisticRegression from sklearn import metrics from sklearn.model_selection import train_test_split

X_train = train.drop('Survived', axis=1).values
target_label = train['Survived'].values

X_test = test.values
```

(3) 그 후 train set과 test set을 분리했다.

(4) logistic regression으로 model을 생성하고, 모델을 학습시킨다(model.fit) 그후, model 에 test set의 x를 넣어 값을 예측한다.


(5) test의 label과 비교해 accuracy를 측정한다. 그 후 confisuion matrix를 생성한 다음, 이를 이용하여 Precision, Recall, F1-score를 측정한다.

```
| [8] print('Number of people: {} \text{ \text{ \text{Minaccuracy: \text{ \cdots \text{ \text{ \cdots \text{ \text{ \cdots \text{ \cdots \text{ \cdots \text{ \cdots \cdot
```

(6) cut off를 조절하여 모델의 성능을 비교해보았다.



(7) 위에서 생성한 모델들을 이용하여 ROC그래프를 그려봤다.



(8) 위의 모델들 중 accuracy가 가장 큰 값의 confusion matrix를 만들었다.

(9) F1스코어가 가장 큰 값을 가지는 모델의 confusion matrix를 그러 †보았다.

3. 5장_나이브베이즈


(1) import 하기

```
[1] from sklearn.datasets import load_iris
import pandas as pd
import numpy as np
from matplotlib import pyplot as plt
```


(2) 꽃의 생김새에 따른 분류 데이터를 load한 후 data를 확인해 보았다.

iris_frame[' X = iris_fra	pd.DataFrame(data=n		iris['target']],colum "versicolor",0:"setos			es'] + ['targ
sepal	length (cm) sepa	width (cm) peta	l length (cm) petal	width (cm)	target	
0	5.1	3.5	1.4	0.2	setosa	
1	4.9	3.0	1.4	0.2	setosa	
2	4.7	3.2	1.3	0.2	setosa	
3	4.6	3.1	1.5	0.2	setosa	
4	5.0	3.6	1.4	0.2	setosa	
145	6.7	3.0	5.2	2.3	virginica	
146	6.3	2.5	5.0	1.9	virginica	
147	6.5	3.0	5.2	2.0	virginica	
148	6.2	3.4	5.4	2.3	virginica	
149	5.9	3.0	5.1	1.8	virginica _V	


(3) sepal length와 sepal width에 대해 어떤 분포를 나타내고 있는지 그래프를 그려보았다.



(4) petal length에 대한 꽃의 분류를 그래프로 그려보았다.



(5) 마찬가지로 petal width에 대한 꽃의 분류를 boxplot을 그려 나타내보았다.



(6) Naive Bayes classifier를 통해 model을 생성하고, fit해보았다.

```
[7] import matplotlib.colors as colors
    from sklearn.naive_bayes import GaussianNB
    df1 = iris_frame[["sepal length (cm)" , "sepal width (cm)", "target" ]]
    X = df1.iloc[:,0:2]
    Y = df1.iloc[:,2].replace({'setosa':0,'versicolor':1,'virginica':2}).copy()
    NB=GaussianNB()
    NB.fit(X,Y)
    N=100
```

(7) 가우시안 나이브 모델을 가시적으로 표현해 보았다.